

无创产前筛查中 cfDNA 浓度阈值的优化方法与实证研究

摘要

本研究重点探讨无创产前筛查（NIPT）中阈值设置的优化。作为核心检测指标的游离胎儿DNA（cfDNA）易受母体个体生理特征和测序技术的影响。母体体质指数（BMI）、采血孕周、测序深度、GC含量等因素均显著影响cfDNA浓度，从而影响检测是否达到理想的临床阈值。然而，现有的临床指南通常采用统一的阈值设置，忽略了人群差异和数据质量波动的影响。

针对问题1，本研究首先分析了胎儿Y染色体浓度与母体孕周、BMI等指标的相关性，并建立了统计学模型。结果显示，孕周是影响cfDNA浓度最显著的正向因素，呈非线性上升趋势。BMI与cfDNA浓度呈显著负相关，且BMI越高，稀释效应越强。此外，双胞胎妊娠会显著增加cfDNA浓度，且实验批次对测序结果具有系统性影响。混合效应线性模型证实了所有这些关系均具有统计学意义。

关于问题2，在分析孕妇BMI对男性胎儿达到目标Y染色体浓度时间的影响时，将孕妇按BMI分层，并为每个组分配BMI范围和推荐的NIPT检测时机。结果显示，不同BMI组的目标孕周中位数存在显著差异。例如，对于BMI ≥ 40 的女性，最佳推荐孕周为24周+2天。敏感性分析进一步验证了推荐时机在阈值波动下的稳健性，确保检测误差对结果的影响在可控范围内，从而有效降低潜在风险。

针对问题3，进一步考虑身高、体重、年龄等多种影响因素，以孕妇BMI为分层指标，并根据综合检测误差和Y染色体浓度达标比例，确定各组最佳NIPT时机。结果表明，孕周与BMI的交互作用对cfDNA浓度的变化具有显著影响。通过构建生存分析模型并进行分层检验，验证了该方法在多变量条件下预测最佳孕周的有效性。结果表明，该方法有效降低了跨BMI组检测的风险，提高了筛查结果的准确性和稳健性。

针对问题4，对于怀有女性胎儿的孕妇，由于她们不携带Y染色体，因此本研究的重点是确定她们是否存在染色体异常。本研究以21、18和13号染色体的非整倍体作为判断染色体异常的标准。综合考虑X染色体及上述染色体的Z值、GC含量、校正读段数、BMI等因素，我们基于**XGBoost模型**构建了分类方法。结果表明，该模型能够有效检测女性胎儿异常，并具有较高的灵敏度和特异性，具有临床应用价值。研究结论为差异化的NIPT检测策略提供了可靠的理论和实证支持。

关键词：无创产前检测；cfDNA；Y染色体浓度；孕妇BMI；最佳检测时点，广义线性模型，混合效应模型，非整倍体判定，XGBoost模型，生存分析，Cox模型，比例风险模型

一、引言

无创产前检测 (NIPT, Non-invasive Prenatal Test) 通过孕妇外周血中游离胎儿 DNA 的测序和定量分析, 其方法可在孕期早期对胎儿染色体异常 (如21、18、13号三体) 进行高灵敏度筛查。相比于现有的有创诊断方法, NIPT 具有创伤小、风险低、可重复采样等优势, 已逐步成为产前筛查的重要方式。然而, NIPT 的判定准确度受多种因素影响, 其中尤其胎儿染色体浓度 (主要为男胎 Y 染色体浓度) 随孕周变化、孕妇体质指数 (BMI) 对胎儿游离 DNA (cfDNA) 浓度的影响、测序深度、GC 偏倚、测序失败率和重复测序等问题存在, 都可能导致假阴性、假阳性或测序无法判定的情况。临床实践表明, 如若不能合理选择检测时点、不考虑个体差异以及各种因素之间的互相影响, 可能导致“治疗窗口期”缩短或延误确诊, 从而对胎儿和母体健康带来负面影响。

本题基于某地区孕妇NIPT 数据 (样本中高 BMI 比例较大), 旨在通过数据驱动的方法研究: 男胎 Y 染色体浓度与孕周、BMI 等指标的关系; 如何为不同组 BMI 群体确定最佳 NIPT 时点; 在考虑多个协变量与检测误差情况下优化时点选择策略; 以及如何在女胎情况下结合综合多项测序与质控指标对21、18、13号染色体非整倍体结果做出准确判定。研究既有理论意义, 也具备重要临床价值 (为高 BMI 群体制定差异化检测建议、降低漏诊/误诊率)。

二、问题重述

2.1 问题背景

数据来源: 数据附件提供了某地区的 NIPT 检测数据, 样本中高 BMI 孕妇居多, 其变量包含孕周、身高、体重、BMI、年龄、胎儿性别判定结果 (男/女)、各染色体的 Z 值与读段数、GC 含量、测序质控指标、是否测序失败、以及部分个体的多次采血 (多次测序记录)。

关键临床判定阈值: 命题中将男胎 Y 染色体浓度 $\geq 4\%$ 作为“达标”的判定阈值; 21、18、13号染色体的 Z 值或 AB 列被用于判断是否非整倍体 (异常)。

问题难点: 存在测序失败 (可能与孕周、BMI、样本量以及测序深度等多方面有关); 部分孕妇有重复测序记录; 样本中个体差异大 (如年龄、体重、身高、BMI、妊娠周不同), 并可能存在测量误差与系统性偏倚 (如GC偏倚、读段数影响)。

2.2 基本问题

问题 1 (仅男胎, 相关性分析与建模)

目标: 分析胎儿 Y 染色体浓度与孕周、BMI 值及其他可用协变量 (如年龄、身高、体重、读段数、GC 含量等指标) 之间的相关特性, 最终构建能够预测 Y 染色体浓度随孕周变化的统计或回归模型, 并对其模型中显著性进行检验。

具体要求与注意点:

- (1) 考虑重复测序 (个体内相关性) 与测序失败 (缺失或删失数据) 等问题;
- (2) 考虑 Y 浓度与孕周的非线性关系;
- (3) 考虑变量效应方向与效应量 (例如: 孕周或 BMI 每单位变化对应的 Y 浓度变化), 并进行显著性检验与模型诊断结果。

问题 2 (仅男胎, 按 BMI 分组确定最佳 NIPT 时点, 分析误差影响)

目标: 基于胎儿中男胎样本, 验证并量化 BMI 值对“Y 染色体浓度首次达到 $\geq 4\%$ 最早时间”数据的影响; 对男胎孕妇进行合理的 BMI 数值分组, 为每一组别推荐最佳 NIPT 时点, 使孕妇潜在风险 (如因过早检测导致测序失败或因过晚检测导致治疗窗口缩短) 最小化, 并分析检测误差对推荐时点的影响。具体要求与注意点:

- (1) 将“首次达到 $\geq 4\%$ ”条件设定为时间到事件问题（含删失），采用生存分析（Kaplan-Meier、Cox 或 AFT方法）估计BMI分组差异与达标概率随孕周的变化；
- (2) 明确损失/决策准则（如达到某一达标概率阈值 p^* 时的最早孕周，或最小化一个包含未达标概率与测序失败概率的期望损失函数）；
- (3) 用敏感性分析（bootstrap、蒙特卡罗模型）以及评估测序误差和阈值变动（例如 3.5% - 4.5%范围）对推荐时点的影响。

问题 3（综合多因素，按 BMI 分组的最优时点——含更多协变量与误差建模）

目标：在问题 2 的基础上综合更多影响达标时间的因素（如孕妇身高、体重、年龄、测序质控指标等），系统考虑检测误差与胎儿 Y 浓度观测噪声，构建更全面准确的决策预测模型，并基于模型为不同 BMI 组孕妇给出更加稳健的最佳 NIPT 时点建议，并同样评估检测误差对结果的影响。

具体要求与注意点：

- (1) 使用多变量生存模型或带误差校正的模型（SIMEX、贝叶斯测量误差模型等）来缩小观测误差对参数估计与预测的误差以提高精准度；
- (2) 若样本存在重复采样，可采用混合效应/frailty 模型来整合个体级别随机效应；
- (3) 输出每个 BMI 组在不同置信水平下的推荐检测周数（给出置信区间或后验分布），并通过模拟（不同误差假设情景）展示策略稳健性。

问题 4（女胎异常判定方法）

目标：针对胎儿中女胎样本（其不携带 Y 染色体），基于给出的特定染色体21、18、13号，其非整倍体标识（AB 列）以及 X 染色体的 Z 值、各染色体的 Z 值、GC 含量、读段数与相关比例以及BMI 值等变量，学习构建一个女胎异常（染色体非整倍体异常）的综合分类模型，给出决定性判定规则，并测试评估其性能与临床适用性。

具体要求与注意点：

- (1) 特征工程需要包含指标：各染色体的 Z 值（或归一化读段数）、X 染色体特征、纠正后的GC读段数或比率、测序质控指标（coverage、mapping rate）、孕周以及 BMI值；
- (2) 模型形式可选：逻辑回归（可解释性强）、XGBoost（预测能力强）、或贝叶斯模型（具有融合先验风险能力）；需处理样本中分类不平衡问题并输出灵敏度、特异度、AUC、PR 曲线等评价指标；
- (3) 最终给出判定概率的阈值策略（如高灵敏度筛查阈值 + 后续确诊建议），并对多次检测结果的整合及测序偏倚（GC/读段数）如何校正做出说明。

2.3 共性假设与数据处理原则

- (1) 统一阈值假设：Y 浓度 $\geq 4\%$ 被视为“标准”判断标准（若需要进行敏感性分析，阈值可以调整）；21/18/13 的 Z 值以及 AB 列是参考标签。
- (2) 重复测量：对同一孕妇进行多次采样或者测序被视为纵向数据，应使用混合效应或贝叶斯更新方法来整合信息，而不是忽略可重复性。
- (3) 测序失败和缺失：需要分析失败的机制（MCAR、MAR 或 MNAR），并根据机制采用适当的缺失处理（缺失存活模型、加权方法或联合建模）。
- (4) 质量控制：在建模或将其用作模型中的校准变量之前，对读取段计数、GC 含量、映射率等质量控制指标进行必要的筛选。
- (5) 明确决策标准：在提供“最佳时间点”和“决策规则”时，应同时报告选择时间点/阈值所依据的统计阈值（如满足标准 p^* 的概率）或损失函数形式，并提供不确定性度量（置信区间或后验概率区间）。

表格 1-变量符号表

符号 / 缩写	说明	取值 / 单位
cfDNA	胎儿游离 DNA 浓度	% 或比例
BMI	孕妇体质指数 (Body Mass Index)	kg/m ²
GA / 孕周	孕妇怀孕周数	周 (w) 或天 (d)
Y_conc	男胎 Y 染色体浓度	% 或比例
θ / θ_0	cfDNA 达标阈值	4%
T	事件时间: 首次达到 cfDNA 阈值的孕周	天或周
S(t)	生存函数: 尚未达标的概率	0 - 1
HR	风险比 (Hazard Ratio)	无量纲
R ²	决定系数	0 - 1
MSE	均方误差	单位同 cfDNA
AIC	赤池信息准则	无量纲
BIC	贝叶斯信息准则	无量纲
n	样本量	人数
IVF / IUI	辅助生殖方式	IVF: 试管婴儿, IUI: 人工授精
GC	测序 GC 含量	%
Reads	测序读段数	条数
Unique Reads	唯一比对的读段数	条数
Filtered Reads	被过滤读段比例	%
Duplicate Reads	重复读段比例	%
Z 值	染色体 Z-score, 用于非整倍体判定	标准化分数
Twins	单胎/双胞胎	0 = 单胎, 1 = 双胞胎
FetalSex	胎儿性别	M = 男, F = 女
Batch	实验批次或测序平台	分类变量
LMP	末次月经	日期

三、问题分析


3.1 问题一分析

3.1.1 模型建立

问题一的核心是如何确定胎儿游离DNA (cfDNA) 检测结果的准确性, 并从检测样本中提取有效数据。考虑到 cfDNA 浓度容易受到母体特征和测序技术条件的影响, 直接使用样本中原始数据进行建模可能会导致阈值设置偏差, 从而影响产前筛查的准确性。因

此，本问题使用广义线性模型（GLM）和混合效应模型来控制孕妇之间的个体差异，同时分析孕龄、BMI和测序质量指标对cfDNA浓度的影响。通过结合数据分布和ROC曲线分析来优化阈值。

图表 1-问题一思维导图



3.1.2 数据分析与处理

① 变量筛选与分类

根据文献经验和生理机制，变量分为三类：

建模推荐变量：胎龄BMI、原始读取片段计数、唯一比较读取片段计数，GC含量，过滤读取片段比率，重复读取片段比率、IVF妊娠；

可选变量：胎龄、产次、产妇年龄、检查次数；

排除变量：末次月经（与胎龄高度相关）、检测日期（没有直接的生理意义）、非二倍体和健康结果（因变量）。

孕龄检测的标准化：将原始数据中类似于“11w+6”的字符串格式转换为孕龄的整数表示。例如，“11w+6”转换为12周。如果有小数形式（如11.8周），请根据小数部分将其转换为天数，并四舍五入到整个妊娠周。

孕妇的BMI处理：将孕妇的BMI值四舍五入，并将其转换为整数变量进行分组和比较分析。

缺失值填充：对于末次月经（LMP）字段，该模式用于填充缺失值，以确保时间相关变量的完整性。

IVF妊娠方法的分类：将妊娠方法分为三个离散变量：0表示自然受孕，1表示人工授精（IUI），2表示体外受精（IVF），以实现变量的数值分类。

高偏度变量的对数变换：为了避免“原始读取段数”和“唯一比较的读取段数来”的分布中的过度偏度影响模型拟合，本文对两者都采用对数变换（log1p），在保持相对差异的同时减轻了极值的影响。

转换生育史变量：将“怀孕次数”和“出生次数”变量转换为二元指标变量，其中“1”表示至少经历过一次怀孕或分娩，“0”表示没有经历。

② 剔除变量的原因分析（数理逻辑支撑）

(1) 因果方向性 (Causality)

建模目的为解释胎儿 Y 染色体浓度 Y 随孕周、BMI 等母体特征如何变化。一些指标（如 Z 值、是否异常、是否健康）本质上是基于 Y 及测序质量推导出来的结果：

$$Z = f(Y, \text{测序质量})$$

因果方向为 $Y \rightarrow Z$ ，若将 Z 作为因变量会造成因果倒置（outcome 预测 outcome），破坏模型解释力。

(2) 冗余性 (Redundancy)

如 X 染色体浓度、Z 值与 Y 浓度存在函数关系：

$$X_{\text{conc}} = g(Y_{\text{conc}}), Z_{21} = h(\text{reads}, Y_{\text{conc}})$$

若其作为因变量或解释变量，将造成严重共线性，违背回归模型中“自变量独立”的假设，使估计结果无效。

(3) 无解释性 (Lack of explanatory power)

“末次月经”“检测日期”等仅为记录性变量，对 Y 浓度没有直接生物学解释。数学上表现为：

$$E[Y | \text{检测日期}] \approx E[Y]$$

即其条件期望与边际期望无显著差别，不具备预测意义。


③异常值与缺失值处理

对样本中连续变量采用分位数法进行筛选，例如：

$$X_i \in [Q_{0.01}(X), Q_{0.99}(X)]$$

以剔除超出 1% - 99% 分位数范围的极端值，避免异常点影响回归结果。

图表 2-孕妇特征与测序指标的标准化分布图



图表 2显示了各种临床和测序指标的分布特征。结果表明，大多数变量在标准化后呈现出近似对称的分布，分布中心接近0，总体上符合正态分布特征。这表明，通过对数变换和标准化，来自不同来源和维度的变量已被有效地统一到同一度量体系中，使其具有可比性。该处理为后续的相关性分析和回归建模奠定了坚实的数据基础。


⑤单变量显著性检验

连续变量采用 Pearson 相关系数：

$$r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$


分类变量采用 Mann - Whitney U 检验，检验不同分组间 Y 浓度差异。

图表 3-Y染色体浓度与各变量的 Spearman 相关性条形图



图表 3显示了cfDNA浓度与临床和测序指标之间的相关性。结果显示，胎龄与cfDNA浓度呈轻度正相关；BMI、年龄与比较率呈显著负相关；原始读取段的数量与唯一对数之间也存在微弱的负相关关系；重复读数的比例和过滤的比例呈正相关；然而，GC含量没有显著相关性。这表明母体特征和测序质量都对cfDNA浓度有影响。

图表 4-分类型变量与 Y 染色体浓度的箱线图



图表 4Error! Reference source not found. 对候选变量与Y染色体浓度之间的关系进行Spearman秩相关分析后发现，胎龄与Y染色体含量之间存在最显著的正相关关系（ r 值最高）， $p < 0.001$ 。这表明Y染色体浓度随着胎龄的增加而增加。孕妇的BMI与Y染色体浓度呈显著负相关（ $p < 0.01$ ），这与高BMI稀释血浆cfDNA的医学解释一致。年龄变量之间的相关性较弱，不够显著。在测序相关指标中，原始读取次数、唯一比对读取次数以及与参考基因组的比较均与Y染色体浓度呈正相关，而重复读取和过滤读取的比例与Y浓度呈负相关，表明数据质量对检测灵敏度有一定影响。

在多重共线性检验中，VIF结果表明，大多数变量的VIF值小于5，表明没有严重的共线性问题；然而，“原始读取段数”和“唯一读取段比较数”（VIF接近10的边界）之间存在一定的相关性，在建模过程中需要考虑到这一点。总体而言，数据中没有明显的多重共线性，后续模型可以在保留主要变量的同时做出稳健的估计。

表格 2-VIF 多重共线性检验结果

变量	VIF
检测孕周	1.041
孕妇 BMI	1.027
原始读段数	1.597
唯一比对的读段数	1.596
GC 含量	1.013
被过滤掉读段数的比例	1.096
年龄	1.008
在参考基因组上比对的比例	1.103
重复读段的比例	1.051

VIF检测对重要自变量进行了多重共线性检验。其结果如表格 2所示，各变量的 VIF 值均接近 1，其值远低于常用的阈值 5，表明模型没有存在明显的多重共线性问题，变量之间的独立性较好。

⑥建模思路与扩展

在正式建模中，我们采用 GLM 模型分析主要变量对 Y 浓度的影响：

$$\log(\mu_i) = \beta_0 + \beta_1 \text{孕周}_i + \beta_2 \text{BMI}_i + \beta_3 \text{读段数}_i + \dots$$

其次引入了孕妇个体的随机效应，构建混合效应模型：

$$\log(\mu_{ij}) = \beta_0 + \beta_1 X_{ij} + u_{ij} + \epsilon_{ij}$$


$$u_j \sim N(0, \sigma_u^2)$$

其中 u_j 表示孕妇个体层面的随机效应， ϵ_{ij} 表示模型残差。随后，我们使用广义加性模型（GAM）来预测潜在的非线性关系：

$$g(\mu_i) = \beta_0 + f_1 \text{孕周}_i + f_2 \text{BMI}_i + f_3 \text{GC 含量}_i + \dots$$

其中 $f_k(\cdot)$ 为平滑函数，能够更灵活地刻画非线性效应。

图表 5-残差 vs 拟合值图



表格 3-混合效应线性回归结果

	系数 (Coef.)	标准差 (Std. Err)	$P > z $
常数项	-2. 652***	0. 025	0. 000
孕周	0. 172***	0. 009	0. 000
BMI	-0. 057***	0. 021	0. 006
原始测序读段数	-0. 025*	0. 010	0. 014
唯一对比率	-0. 030**	0. 010	0. 004
年龄	-0. 044	0. 026	0. 083
对比率	-0. 012	0. 009	0. 158
重复率	0. 005	0. 009	0. 567
组件方差)	0. 157	0. 073	

表格 3结果表明不同繁殖方式的Y染色体浓度存在一定差异。自然受孕组、人工授精（IUI）组和体外受精（IVF）组的浓度分布显示出一定的波动，体外受精组的总体分布更加离散，这表明它可能受到更复杂的临床或技术因素的影响。妊娠频率和分娩频率的分组分析还揭示了不同妊娠经历下Y染色体浓度的差异：一些组的平均值和中位数存在显著差异，这进一步得到了Mann-Whitney U检验和Kruskal-Wallis检验的验证，差异具有统计学意义。


从图形结果来看，箱图和散点图清楚地显示了不同群体的分布特征：自然受孕组的Y染色体浓度相对集中，而试管婴儿组的分布更广，表明在辅助生殖的背景下，cfDNA浓度可能存在更大的不确定性。这一发现为后续模型的建立提供了重要参考，表明在分析cfDNA浓度时应充分考虑生殖方式和生殖史的潜在影响。

3.2 问题二分析

3.2.1 模型建立

问题二的核心是，检测孕妇的不同BMI水平会影响游离胎儿DNA（cfDNA）达到检测阈值的胎龄，从而影响NIPT（非侵入性产前检测）的最佳检测时间。为了科学合理地为不同BMI人群推荐最佳胎龄，本研究使用了生存分析模型（Cox比例风险模型、Kaplan-Meier曲线）和联合敏感性分析来验证推荐时间点对阈值设置的稳健性。

图表 6-问题二思维导图



3.2.2 数据分析与处理

根据题目和附件数据，我们首先进行了以下数据清理和预处理：

① 变量选择

孕妇 BMI：影响母体血容量和 cfDNA 稀释度，核心解释变量；
检测孕周：通过统一转换（如“13w+5” → 13×7+5=96天）得到连续时间变量；
Y 染色体浓度：作为事件判定依据，超过阈值即视为 cfDNA 浓度达标。

② 缺失值与异常值处理

删除 BMI < 12 或 > 60 的极端值；
删除孕周 < 70 天或 > 300 天的异常记录；
删除 Y 浓度缺失的样本。

③ 阈值与事件变量

根据文献经验与数据分布，采用 95% 分位数自适应单位判别：

$$\begin{cases} 1, \text{若 } y_i \geq \theta \\ 0, \text{若 } y_i < \theta \end{cases}$$

其中 $\theta=0.04$ （比例制）或 $\theta=4.0\%$ （百分数制）。

④ BMI 分组

采用临床常见分组标准：

$$BMI组 \in \{[20,28), [28,32), [32,36), [36,40), [40, +)\}$$

3.2.3 模型方法

1. Kaplan - Meier (KM) 生存曲线


定义生存函数：

$$S(t) = P(T > t)$$

其中 T 表示“cfDNA 浓度首次达标的孕周”。

通过 KM 曲线比较不同 BMI 组的“尚未达标”概率。

图表 7-KM曲线



2. Cox 比例风险模型

(1) 风险函数：

$$h(t | X) = h_0(t) \exp(\beta^T \cdot BMI)$$

$h(t | X)$ ：基准风险函数在孕周 t 时的瞬时达标风险；

$h_0(t)$ ：基准风险函数；

X: 协变量 (BMI 分组) ;

β : BMI系数。

(2) 生存函数:

$$S(t | X) = \exp\left(-\int_0^t h(u | X) du\right) = \hat{S}_0(t) \exp(\beta^T X)$$

(3) 部分似然函数 (Partial Likelihood):

设第 i 个孕妇在孕周 t_i 达标, 风险集为 $R(t_i)$, 则:


$$L(\beta) = \prod_{i=1}^D \frac{\exp(\beta^T X_i)}{\sum_{j \in R(t_i)} \exp(\beta^T X_j)}$$

对数似然模型:

$$\ell(\beta) = \sum_{i=1}^D (\beta^T X_i - \ln(\sum_{j \in R(t_i)} \exp(\beta^T X_j)))$$

模型通过极大化 $\ell(\beta)$ 估计 $\hat{\beta}$ 。

图表 8-BMI分组对比图



(4) 风险比 (HR):

$$HR = \exp(\beta)$$

若 $HR > 1$: BMI 增加, cfDNA 达标加快;

若 $HR < 1$: BMI 增加, cfDNA 达标延缓。

(5) 比例风险假设检验:

采用 Schoenfeld 残差:

$$r_{ik} = x_{ik} - \frac{\sum_{j \in R(t_i)} \exp(\beta^T X_j)}{\sum_{j \in R(t_i)} \exp(\beta^T X_j)}$$

若残差与时间无关，则比例风险假设成立。模型估计得到 HR（风险比）与置信区间，检验 BMI 对 cfDNA 达标时间的显著影响。

3. 模型评价指标

采用一致性指数 C-index 指数 衡量模型预测与真实结果的一致性:


$$C = P(\hat{T}_i < \hat{T}_j | T_i < T_j)$$

取值范围 0.5 - 1.0，越接近 1.0 表示模型预测效果越好。

3.2.4 推荐检测时点

根据 Cox 模型预测的中位达标孕周，推荐不同 BMI 组的最佳 NIPT 检测时间；进一步进行了敏感性分析，比 $\theta = 3.7\%, 4.0\%, 4.3\%$ 三个阈值下的推荐时点，验证结果的稳健性。

图表 9-孕妇BMI残差图



表格 4-问题二结果表格

分组方案	分组方法	组别	样本数	推荐日 / 推荐孕周
方案1	DP分箱	$[-\text{inf}, 28.517)$	5537	24w+3
方案2	DP分箱	$[28.517, 29.031)$	906	23w+5
方案3	DP分箱	$[29.031, 36.611)$	34	24w+2
方案4	DP分箱	$[36.611, 37.475)$	50	25w+5
方案5	DP分箱	$[37.475, \text{inf})$	183	26w+4
方案6	K-means	K5_1	366	24w+0
方案7	K-means	K5_2	316	24w+2
方案8	K-means	K5_3	539	24w+1
方案9	K-means	K5_4	413	26w+1
方案10	K-means	K5_5	171	26w+2
方案11	原题分组	$[20, 28)$	166	24w+0
方案12	原题分组	$[28, 32)$	170	24w+2
方案13	原题分组	$[32, 36)$	180	24w+4
方案14	原题分组	$[36, 40)$	186	25w+3
方案15	原题分组	$[40, +)$	168	27w+0


3.3 问题三分析

3.3.1 模型建立

问题三的核心是筛选和确定附件中提供的孕妇大规模临床数据中显著影响胎儿游离DNA（cfDNA）浓度的关键因素，然后建立一个稳健、可解释和预测的模型。cfDNA浓度是确定无创产前检测（NIPT）有效性的基础，因此问题一的基本任务是通过统计建模揭示孕龄、孕妇个体差异以及胎儿相关因素与cfDNA浓度之间的关系。

本问题采用广义线性模型（GLM）、混合效应模型（mixed LM）和广义加性模型（GAM），通过多个指标比较模型拟合效果和预测能力，最终为后续检测策略的优化提供了坚实的经验证据（问题2）。

图表 10-问题三思维导图



3.3.2 数据分析与处理

① 变量选择

在数据清理后，我们主要考虑以下候选变量：

孕周（Gestational Age, GA）：核心解释变量，决定 cfDNA 生成量；

孕妇年龄（Maternal Age）：可能影响胎盘功能与 cfDNA 释放；

孕妇 BMI：影响血浆体积与 cfDNA 稀释效应；

胎儿性别（Fetal Sex）：男胎可检测到 Y 染色体片段，可能影响浓度分布；

单胎/双胞胎（Singleton vs. Twins）：双胞胎胎盘组织更多，cfDNA 浓度可能更高；

实验批次或测序平台（Batch Effect）：作为潜在混杂变量。

② 数据清理与异常值处理

删除孕周 < 60 天或 > 300 天的极端值；

删除 BMI < 12 或 > 60 的异常值；

对孕妇年龄 < 15 岁或 > 50 岁的样本进行剔除；

对连续变量采用中位数插补，对分类变量采用众数插补。

③ 因变量设定

设 cfDNA 浓度为因变量 Y_i ，为了缓解偏态分布并满足正态性假设，进行对数变换：

$$Y_i = \ln(\text{cfDNA浓度}_i)$$

处理后因变量近似正态分布，数据适合后续回归分析。

3.3.3 模型方法

（1）区间删失的构造与阈值判定

测试数据通常是孕妇在多个血液采样点形成的序列。因此，我们不粗略地将“第一次依从时间”近似

为某个观察到的胎龄，而是严格地将其构造为区间删失：(a, b]。其中，b是第一次依从性测试的日期，a是最近一次依从性检测的日期。如果加入组时已经达到标准，则记录为左删除 (a=-∞)；如果在随访期间未达到标准，则将记录为右删除 (b=+∞)。阈值设置为4%，程序将自动将原始单位识别为比率 (0-1) 或百分比 (0-100)，以确保口径的一致性。这种方法的优点是，它保留了“首次成功”的临床意义，同时准确地对应于区间的截断似然函数，避免了将不确定性压缩到单个时间点造成的偏差。

阈值自动判定：若 $Quantile_{0.95}(Y) \leq 1$, 则 $c = 0.04$ ；否则 $c = 4$

区间表示：(a_i, b_i], $a_i = \max\{t: y(t) < c, t < b_i\}$, $b_i = \min\{t: y(t) \geq c\}$

(2) AFT 模型与生存函数

在标准时间的建模层面，我们采用了加速故障时间模型。AFT的想法是让协变量通过线性预测器在对数时间尺度上拉伸或压缩整个时间轴，从而获得随协变量变化的事件时间分布。如果 x_i 表示第 i 位孕妇的协变量向量（包括标准化连续变量和伪变量），则对数时间遵循线性结构，误差项来自给定的分布族。本文比较了常用的对数正态分布族和威布尔分布族，并使用BIC最优作为最终模型。

$$\text{Log}T_i = \mu(x_i) + oEi, \mu(x_i) = \beta_0 + \beta_i, 8\epsilon i \text{ 服从给定分布}$$

对于对数正态模型，生存函数与标准正态分布函数直接对应；对于 Weibull-AFT，形状参数固定，尺度参数对协变量指数变换，生存函数为指数幂形式。

$$\begin{aligned} \text{LogNormal - AFT: } S(t|x) &= 1 - \Phi\left(\frac{\ln t - \mu(x)}{\sigma}\right) \\ \text{Weibull - AFT: } S(t|x) &= \exp\{-(t/\lambda(x))^k\}, \log \lambda(x) = \mu(x) \end{aligned}$$

(3) 区间删失的似然与正则化估计

在区间截尾数据上，似然函数由四种类型的观测贡献组成：精确时间、右截尾、左截尾和区间截尾。在实际估计中，我们使用最大似然的岭正则化来稳定由小样本或多个协变量引起的方差膨胀。同时，我们通过BIC共同选择分布族和正则化强度。

$$\mathcal{L}(\theta) = \prod_{i \in \mathcal{I}_{\text{exact}}} f(t_i | x_i; \theta) \prod_{i \in \mathcal{I}_{\text{right}}} S(L_i | x_i; \theta) \prod_{i \in \mathcal{I}_{\text{left}}} (1 - S(R_i | x_i; \theta)) \prod_{i \in \mathcal{I}_{\text{interval}}} (S(L_i | x_i; \theta) - S(R_i | x_i; \theta)).$$

$$\text{惩罚对数似然: } \ell_{\lambda}(\theta) = \log \mathcal{L}(\theta) - \frac{\lambda}{2} \|\beta\|_2^2.$$

$$\text{模型选择: } \text{BIC} = -2 \log \mathcal{L}(\hat{\theta}) + k \log n.$$

(4) 达标概率、时间积分与风险函数

模型拟合完成后，我们可以得到每个时间点“尚未达标”的概率曲线（生存函数）和“已经达标”的互补累积概率曲线。为了将“尽早完成测试”和“确保足够的确定性”这两个看似矛盾的目标放在同一个标尺上，我们首先对累积合规概率随时间的轨迹进行归一化，即对从开始时间到候选测试日的总体合规概率进行平均，并获得随时间增加的平均合规率曲线。随后，“越早越好”的动机表现为“当前不达标的概率”，“长期低返工概率”的隐患表现为“早期平均合规率”。根据固定权重将两者线性相加，以获得单调可比的综合风险指标。该指标越小，越表明既没有过度鲁莽，也没有延迟到返工风险增加的程度。因此，其最低点可以用作该个人或团体的最佳NIPT测试日期。在数值实现方面，我们将时间线离散化为每日网格，并使用梯形方法对概率曲线进行累积近似。这不仅避免了对函数形式的额外假设，而且稳定地服务于后续的自动搜索和组推荐。

$$\pi(t | x) = 1 - S(t | x).$$

$$\bar{\pi}(t | x) = \frac{1}{t - t_0 + 1} \int_{t_0}^t \pi(u | x) du.$$

$$L(t | x) = \alpha \cdot (1 - \pi(t | x)) + \beta \cdot \bar{\pi}(t | x).$$

(5) 个体化推荐的受约束最优化

临床可行范围设定为“胎龄不早于11周（77天），符合标准的概率不低于0.90”。在这个可行区域内，我们的目标是最小化风险函数并选择个性化的最佳推荐时间点；如果一个人在可行范围内始终未能达到0.90，他们将回到只适用“胎龄不早于11周”的弱约束。将整个电网中风险最低的时间点作为折衷解决方案，并报告此时达到标准的概率，以表明稳定性。

$$t_i^* = \arg \min_{t \geq 77, \pi(t | x_i) \geq 0.90} L(t | x_i),$$

若无解，则 $t_i^* = \arg \min_{t \geq 77} L(t | x_i)$.

(6) 组级推荐：先聚合再决策

为了在临床实践中输出更易于操作的“分组时间点”，我们采用了“先汇总，后决策”的方法。具体方法不是直接计算个人的平均值，而是首先对同一组内每个时间点的累积合规概率和风险函数进行平均，然后将可行区域内的组平均风险最小化，作为该组的推荐时间点。这可以减少少数极端个体对群体推荐的影响，更符合“群体导向出版策略”的实际要求。

$$\bar{\pi}_G(t) = \frac{1}{|G|} \sum_{i \in G} \pi(t | x_i), \quad \bar{L}_G(t) = \frac{1}{|G|} \sum_{i \in G} L(t | x_i).$$

$$t_G^* = \arg \min_{t \geq 77, \bar{\pi}_G(t) \geq 0.90} \bar{L}_G(t), \quad \text{不可行时改为 } \arg \min_{t \geq 77} \bar{L}_G(t).$$

(7) 数据驱动的 BMI 分组

除了问题分组外，我们还提供了两个完全由数据驱动的解决方案，并在相同的模型和决策标准下计算相应的推荐时间点。一组是K-means聚类，它首先将BMI聚类成五个聚类，然后从中心到中心进行排序，并使用相邻中心的中点作为边界来确定五个区间；另一种方法是动态规划的最优合并，它按BMI的升序排列样本，并将任何区间的“成本”定义为该区间在时间网格上的“群体平均风险”的最小值（如果在可行域内无法达到0.90，则在整个网格内取最小值）。以最小化总成本为目标，将样本分为五个部分，并添加了“每个部分不小于最小样本量”的约束。

$$\text{K-means 边界: } m_k = \frac{c_k + c_{k+1}}{2}, \quad k = 1, \dots, 4; \quad \text{区间 } (-\infty, m_1], (m_1, m_2], \dots, (m_4, +\infty),$$

$$\text{DP 代价: } \text{score}(i, j) = \min_t \bar{L}_{[i:j]}(t), \quad \text{若 } \bar{\pi}_{[i:j]}(t) \geq 0.90 \text{ 不可行, 则在全网格上取 } \min_t \bar{L}_{[i:j]}(t).$$

$$\text{DP 目标: } \min_{(i_1, j_1), \dots, (i_5, j_5)} \sum_{k=1}^5 \text{score}(i_k, j_k) \quad \text{subject to } i_1 = 1, j_5 = N, i_{k+1} = j_k + 1, j_k - i_k + 1 \geq n_{\min}.$$

(8) 经验曲线与时间依赖 Brier 的校准检视

为了从实证数据的角度检验时间维度的合理性，我们在“伪右删失”规则下构建了事件时间和事件指标，并在三组分组维度下绘制了1-KM（达到标准的累积经验）曲线，并将其与建模的概率曲线进行了比较。此外，我们使用基于删失的逆概率加权近似来计算时间依赖的Brier分数，并关注其随时间的下降趋势，以衡量概率预测的整体校准。这可以形成“模型数据临床直觉”之间的闭环验证。

$$\text{伪右删失: } T_i = \begin{cases} b_i, & b_i < \infty \\ \max(a_i, 1), & b_i = \infty \end{cases}, \quad E_i = \mathbf{1}\{b_i < \infty\}.$$

$$\text{Brier}(t) \approx \frac{1}{n} \sum_{i=1}^n w_i(t) (\mathbf{1}\{T_i > t\} - S_i(t))^2, \quad w_i(t) = \begin{cases} 1/G(T_i^-), & T_i \leq t, E_i = 1 \\ 1/G(t), & T_i > t \\ 0, & \text{otherwise} \end{cases}.$$

(9) 调参与稳定性

模型选择在“分布族x正则化强度”的联合网格上完成，并通过BIC选择最优组合。绘制BIC分析器曲线和系数路径图，以观察正则化对每个协变量的影响。需要强调的是，无论使用问题面分组、K-means分组还是DP分组，推荐时间点的计算标准都是完全一致的，都来自同一组概率曲线、约束和目标函数，从而确保了三个方案之间的公平可比性。

3.3.4 模型评价指标

为了全面比较不同模型的表现，采用以下指标：

赤池信息准则（AIC）与 贝叶斯信息准则（BIC）：衡量模型拟合优度与复杂度；

决定系数 R^2 ：解释变量对 cfDNA 浓度的解释能力；

均方误差（MSE）与交叉验证误差（CV Error）：检验模型在训练集与验证集上的预测精度；


残差诊断（Residual Diagnostics）：检验模型假设是否成立，包括正态性和异方差性。

3.3.5 结果解释与意义


通过模型比较，发现：

孕周是影响cfDNA浓度的最显著的积极因素，呈非线性上升趋势；BMI与cfDNA浓度呈显著负相关，这与“高BMI”的医学解释一致→ 增强稀释效应→ “降低cfDNA浓度”；双胎妊娠显著增加了cfDNA浓度，证实了胎盘起源的假设；混合LM中的实验批量效应显著，因此必须加以控制以防止系统偏差。总之，GAM在解释和预测能力方面优于GLM和混合LM，表明了非线性关系在这个问题上的重要性。这一结果为未来优化不同孕妇，特别是高BMI孕妇的检测时间提供了理论支持。


图表 11-BMI分组曲线



图表 12-不同BMI*分布图



图表 13-达标概率热力图



表格 5-问题三结果表格

方案	分组区间	样本量 (n)	组级最佳孕周	达标概率
原始(题面)	[20, 28)	129	18w+3	0.9850
原始(题面)	[28, 32)	150	21w+3	0.9833
原始(题面)	[32, 36)	169	24w+1	0.9795
原始(题面)	[36, 40)	21	24w+2	0.9608
原始(题面)	[40, +)	170	24w+2	0.9048
KMeans (5)	$[-\infty, 30.0)$	143	20w+3	0.9843
KMeans (5)	$[30.0, 32.3)$	153	21w+6	0.9819
KMeans (5)	$[32.3, 35.1)$	169	24w+1	0.9801
KMeans (5)	$[35.1, 40.1)$	170	24w+2	0.9653
KMeans (5)	$[40.1, +\infty)$	170	24w+2	0.9048
DP (K=5, min n $\geq$ 10)	[20.7, 34.5]	218	22w+2	0.9819
DP (K=5, min n $\geq$ 10)	[34.6, 35.3]	111	24w+2	0.9725
DP (K=5, min n $\geq$ 10)	[35.3, 36.6]	170	24w+2	0.9722
DP (K=5, min n $\geq$ 10)	[36.7, 38.6]	170	24w+2	0.9666
DP (K=5, min n $\geq$ 10)	[38.8, 46.9]	170	24w+2	0.9221

为了评估不同胎龄分组方案下NIPT检测的组级最佳时机，我们对原始组、KMeans组和DP组进行了比较分析（表X）。在原始分组方案中，不同胎龄间隔的组级最佳胎龄随着胎龄的增加而向上移动。早期妊娠组（20-28周）的推荐孕龄中位数为18w+3，符合标准的概率最高（0.9850），而晚期妊娠组（40周及以上）的推荐妊娠龄中位数为24w+2，符合标准概率降低至0.9048。这表明早期检测样本更有可能达到检测阈值，而晚期样本仍需要根据胎龄进行适度调整，以确保检测的可靠性。在KMeans分组方案下，每组的间隔划分更加精细，组级的最佳胎龄在20w+3和24w+2之间。达标概率保持在0.9048-0.9843之间，妊娠早期至中期（如30.0-32.3周）达标概率略高于原始组，表明聚类优化可以更准确地确定最佳检测时间点。在DP分组方案中，使用最小样本量约束（min n $\geq$ 10）划分间隔后，组水平的最佳妊娠周集中在22w+2和24w+2之间，达到标准的概率为0.9221-0.9819。该方案稳定了每组中最佳妊娠周数的分布，有助于在临床实践中统一推荐检测时间，同时考虑了妊娠早、中、晚周样本的依从率。

总体来看，三种分组方案均能提供较高的达标概率（>0.90），但通过聚类（KMeans）或最小样本约束（DP）优化后，组级别最佳孕周的确定更加精细和稳定，其为临床制定 NIPT 检测时点提供了科学依据。

3.4 问题四分析

3.4.1 模型建立

这个问题的核心是从所附数据中筛选和确定影响胎儿游离DNA（cfDNA）浓度的关键因素，并建立合理的回归模型进行解释和预测。cfDNA的浓度是非侵入性产前检测（NIPT）有效性的先决条件，因此揭示胎龄、母体特征和胎儿相关变量影响cfDNA的机制对于优化检测时间具有根本意义。

3.4.2 数据分析与处理

(1) 变量选择

设 Y_i 为第 i 位孕妇的 cfDNA 浓度（对数变换后），候选解释变量包括：

孕周： GA_i

孕妇年龄： Age_i

孕妇 BMI： BMI_i

胎儿性别： $FetalSex_i$

单胎/双胞胎： $Twins_i$

实验批次/测序平台： $Batch_j$

连续变量进行标准化：

$$X^{(std)} = \frac{X - \bar{X}}{\sigma_X}$$

(2) 缺失值与异常值处理

删除孕周 $GA_i < 60$ 天或 $GA_i > 300$ 天的样本

删除 $BMI < 12$ 或 $BMI > 60$

删除孕妇年龄 < 15 岁或 > 50 岁

连续变量缺失值用中位数填补，分类变量缺失值用众数填补

(3) 因变量设定

对 cfDNA 浓度取自然对数：

$$Y_i = \ln(\text{cfDNA浓度}_i)$$

3.4.3 模型方法

1) 广义线性模型（GLM）

$$Y_i = \beta_0 + \beta_1 GA_i + \beta_2 BMI_i + \beta_3 Age_i + \beta_4 FetalSex_i + \beta_5 Twins_i + \epsilon_i$$

$$\epsilon_i \sim N(0, \sigma_u^2)$$

使用线性回归模型，检验各解释变量的显著性。

2) 混合效应模型 (MixedLM)

考虑实验批次 jjj 的随机效应：

$$Y_{ij} = \beta_0 + \beta_1 GA_{ij} + \beta_2 BMI_{ij} \dots + u_j + \epsilon_{ij}$$

$$u_j \sim N(0, \sigma_u^2)$$

$$\epsilon_{ij} \sim N(0, \sigma^2)$$

一般形式可写为：

$$Y = X\beta + Z_u + \varepsilon$$

模型中 X 为固定效应设计矩阵，Z 为随机效应设计矩阵。

3) 广义加性模型 (GAM)

考虑孕周和 BMI 的非线性关系：

$$Y_i = \beta_0 + \beta_1 GA_i + \beta_2 BMI_i + \beta_3 Age_i + \beta_4 FetalSex_i + \dots \epsilon_i$$

其中 f1, f2 为平滑函数（如 cubic spline），可捕捉非线性趋势。

4) 特征工程与交互项

结合你 Python 特征工程，模型可扩展为：

$$Y_i = \beta_0 + \beta_1 GA_i + \beta_2 GA_i^2 + \beta_3 BMI_i + \beta_4 BMI_i^2 + \beta_5 Age_i + \beta_6 FetalSex_i + \beta_7 Twins_i \\ + \beta_8 (X_{浓度_i} \times GA_i) + \beta_9 (X_{浓度_i} \times GC_i) + \sum_k \gamma_k Z_{ik} + \epsilon_i$$

其中 Z_{ik} 为分段 (bin) 变量、交互项、比例或差值特征，如：

$$Z_{i1} = 1\{GA_i < 12\}$$

$$Z_{i2} = 1\{GA_i \in [12, 20]\}$$


$$Z_{i3} = \frac{Z_{21,i}}{Z_{13,i} + \epsilon}$$

5) LASSO 特征选择

为控制多重共线性和自动压缩不重要特征，引入 L1 正则化：

$$\hat{\beta} = \arg \min_{\beta} \left\{ \frac{1}{2n} \sum_{i=1}^n (Y_i - X_i \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

图表 14-LASSO选择的特征和系数图



3.4.4 模型评价指标

赤池信息准则 (AIC) : $AIC = 2k - \ln(\hat{L})$

贝叶斯信息准则 (BIC) : $BIC = k \ln(n) - 2 \ln(\hat{L})$

决定系数 $R^2 = 1 - \frac{\sum_i (Y_i - \hat{Y}_i)^2}{\sum_i (Y_i - \bar{Y})^2}$

均方误差 (MSE) :

$$MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

交叉验证误差 (CV Error)

残差诊断: 检查正态性与异方差性

3.4.5 结果解释与意义

在交叉验证 (CV) 中, 模型在女胎异常情况判定上的表现如下 (均值 $\pm$ 标准差) :

表格 6-cv验证结果表格

指标	值
ROC-AUC	0.780 ± 0.061
PR-AUC	0.461 ± 0.097
F1-score	0.510 ± 0.078
Recall	0.587 ± 0.150
Accuracy (ACC)	0.874 ± 0.044
最优阈值 (Best threshold)	0.45 ± 0.020

在模型的性能评估中，我们使用交叉验证（CV）方法系统地测试了女性胎儿异常检测模型。图中显示了各种绩效指标的平均值和标准差，包括ROC-AUC、PR-AUC、F1得分、召回率、准确性和最佳阈值。该模型的ROC-AUC为 0.780 ± 0.061 ，表明该模型在区分异常胎儿和正常胎儿方面具有很强的辨别能力，并且在不同折衷方案下相对稳定。PR-AUC为 0.461 ± 0.097 ，表明该模型在处理类别不平衡问题时识别异常胎儿的能力有限，但仍优于随机猜测。

考虑到准确性和召回率，F1得分为 0.510 ± 0.078 ，表明该模型在捕捉异常胎儿方面达到了中等水平的能力。 0.587 ± 0.150 的召回率意味着该模型可以识别大约59%的实际异常胎儿，表明灵敏度可以接受，但仍存在漏诊的风险。该模型的总体准确度达到 0.874 ± 0.044 ，表明对大多数样本的预测是正确的。然而，由于样本中正常胎儿的比例很高，仅使用准确性可能会高估模型的性能。因此，应结合F1评分和PR-AUC进行综合评价。

女胎异常判定方法（基于OOF概率）：

prob > 0.390
明确正常: prob ≤ 0.340
建议复诊: 0.340 < prob ≤ 0.390 （参考 Youden 最优值 T_youden = 0.379）

表格 7-女胎异常判定下各指标分布表

指标	明确异常 (Q25 - Q75, 中位数)	明确正常 (Q25 - Q75, 中位数)
检测孕周	16.00 - 24.00 (21.00)	13.00 - 20.00 (16.00)
重复读段比例	0.03 - 0.03 (0.03)	0.03 - 0.03 (0.03)
21号染色体 Z 值	-0.62 - -1.02 (0.26)	-0.96 - -0.44 (-0.26)
X 染色体 Z 值	-0.38 - -1.03 (0.44)	-0.19 - -1.33 (0.59)
被过滤读段比例	0.02 - 0.03 (0.02)	0.02 - 0.02 (0.02)
13号染色体 GC 含量	0.38 - 0.38 (0.38)	0.38 - 0.38 (0.38)
GC 含量	0.40 - 0.40 (0.40)	0.40 - 0.40 (0.40)
X 染色体浓度	-0.03 - -0.02 (-0.03)	-0.01 - -0.01 (0.00)
年龄	0.00 - 0.00 (0.00)	0.00 - 0.00 (0.00)
孕妇 BMI	2.00 - 3.00 (2.00)	2.00 - 3.00 (2.00)
生产次数	0.00 - 1.00 (0.00)	0.00 - 1.00 (0.00)

注： 各指标在明确异常与明确正常的孕妇群体中，其均显示出不同的中位数和四分位间距，说明这些指标可能与女胎异常风险相关。模型检测孕周在异常组略高于正常组，而 21 号染色体 Z 值在异常组中位数更高，提示染色体异常特征较为明显。

在异常明显和正常组明显的孕妇中，各项指标显示出不同的分布特征。异常组的中位胎龄为21周（四分位数为16-24周），高于正常组的16周（13-20周），表明异常样本大多在妊娠中后期检测到。异常组21号染色体的Z值中位数为0.26（-0.62至1.02），显著高于正常组的-0.26（-0.96至-0.44），反映出异常组的染色体信号更加明显。

异常组的X染色体Z值和浓度也存在一定差异，而重复片段率、过滤片段率、GC含量和母体BMI等指标的差异相对较小。这些结果表明，21号染色体的Z值和胎龄等关键指标与女性胎儿异常的风险密切相关。

表格 8-女胎“建议复诊”群体指标分布表

指标	建议复诊 (Q25 - Q75, 中位数)
检测孕周	16.00 - 23.00 (19.00)
重复读段比例	0.03 - 0.03 (0.03)
21号染色体 Z 值	-0.64 - -0.82 (0.09)
X 染色体 Z 值	-0.61 - -1.24 (0.46)
被过滤读段比例	0.02 - 0.02 (0.02)
13号染色体 GC 含量	0.38 - 0.38 (0.38)
GC 含量	0.40 - 0.40 (0.40)
X 染色体浓度	-0.02 - -0.01 (-0.02)
年龄	0.00 - 0.00 (0.00)
孕妇 BMI	2.00 - 3.00 (2.00)
生产次数	0.00 - 1.00 (0.00)

注： “建议复诊”组的各指标数值大多介于明确异常组与明确正常组之间，反映该群体存在潜在风险但尚不明确，提示需要后续复查以确认胎儿健康状态。

“推荐随访”组各项指标分布在明显异常组和明显正常组之间。例如，该组的中位胎龄为19周

（16-23周），21号染色体的中位Z值为0.09（-0.64至-0.82），表明该人群存在异常的潜在风险，但尚不清楚。与异常组和正常组相比，X染色体相关指标和其他测量值也处于中等水平，表明需要通过随访检查进一步确认胎儿健康状况。

4. 模型说明

4.1 模型优点

（1）多角度建模：

问题1：利用混合效应模型（MixedLM）系统分析了胎儿Y染色体浓度与孕周、BMI等连续变量的关系，并进行了显著性检验，有效揭示了浓度变化的动态模式。

问题2：引入Cox比例风险模型和Kaplan-Meier生存曲线，并利用K均值聚类 and 最优动态规划（DP）分箱方法优化BMI聚类，降低了不同群体孕妇的潜在风险。

问题3：利用区间删失加速失效时间（AFT，对数正态/威布尔）模型，引入多个协变量（身高、体重、年龄等）和检测误差，构建了个体化目标概率模型，提高了对异质性人群的预测精度。问题4：利用XGBoost，综合考虑X染色体、13/18/21号染色体的Z值以及多项测序指标，建立了女性胎儿非整倍体的判别模型，有效提升了判别的灵敏度和稳健性。

（2）稳健性：所有模型均纳入了GC含量、比对率、重复率等测序质控指标，并对异常值、负值浓度等数据进行了清洗和限制，以减少技术噪声对结果的干扰。

（3）多方法交叉验证：对每个问题均采用敏感性分析（例如阈值范围为3.5%至4.5%）、一致性指数（C指数）、BIC等统计指标，以确保模型的稳健性和可靠性。

8.2 模型的缺点

（1）复杂度高：问题2和3中的聚类优化方法（K均值和PD动态规划）以及AFT区间删除模型需要较大的样本量和计算资源，在社区医院直接实施存在一定难度。

（2）边缘人群的不确定性：对于BMI过低/过高或孕周过早的孕妇，模型的预测结果仍然存在偏差，应结合临床经验谨慎解读。

（3）跨平台适应性有限：虽然模型考虑了测序质控指标，但仍不足以完全消除不同测序平台和批次的影响。未来需要利用跨中心数据进行验证和修正。

8.3 模型推广

本研究提出的阈值优化模型不仅适用于本数据集，而且具有很强的可移植性。在不同地区或不同测序平台推广时，可结合当地孕妇BMI分布及孕周特点适当调整推荐时间点，以保证模型在不同人群中的适用性。在高危人群中，尤其是高BMI孕妇比例较大的地区，该模型可显著降低测序失败率，提高筛查准确率和可及性，为公共卫生资源有限的场景提供切实可行的解决方案。同时，本研究在问题1—3中运用混合效应模型（MixedLM）、Cox模型和AFT模型表征Y染色体浓度的动态变化并预测最佳筛查时间点，这些方法可为临床医生进行个体化随访、制定筛查策略提供科学依据。在问题4中，多指标分类模型为女性胎儿非整倍体风险筛查提供了一种新的思路，具有重要的临床应用价值。未来研究随着大规模多中心数据的发展和前瞻性随访，有望进一步优化本研究提出的各类模型的参数并提升其泛化性能，最终为建立统一、个性化的NIPT检测策略提供坚实的理论基础和方法支持。

附录:

问题1.

4 图像处理

```
import warnings
```

```
warnings.filterwarnings("ignore")
```

```
import pandas as pd
```

```
import numpy as np
```

```
import seaborn as sns
```

```
import matplotlib.pyplot as plt
```

```
import statsmodels.formula.api as smf
```

```
import matplotlib as mpl
```

```
mpl.rcParams['font.family'] = 'Songti SC'
```

```
plt.rcParams['axes.unicode_minus'] = False
```

```
clean_data_input = "附件(问题一数据清理).xlsx"
```

#4.1 读取 & 标准化列名

```
df = pd.read_excel(clean_data_input).copy()
```

```
df.columns = df.columns.str.strip()
```

```
rename = {
```

```
    "孕妇代码": "mother_id",
```

```
    "检测孕周": "gestational_age",
```

```
    "孕妇BMI": "bmi",
```

```
    "原始读段数": "raw_reads",
```

```
    "唯一比对的读段数": "unique_reads",
```

```
    "年龄": "age",
```

```
    "在参考基因组上比对的比例": "map_ratio",
```

```
    "重复读段的比例": "dup_ratio",
```

```
    "Y染色体浓度": "y_fraction",
```

```
}
```

```
df.rename(columns={k: v for k, v in rename.items() if k in df.columns}, inplace=True)
```

#4.2 派生更稳特征 (连续协变量)

```
if {"unique_reads", "raw_reads"}.issubset(df.columns):
```

```
    df["unique_rate"] = pd.to_numeric(df["unique_reads"], errors="coerce") / \
        pd.to_numeric(df["raw_reads"],
```

```
errors="coerce")
```

```
if "raw_reads" in df.columns:
```

```
    df["log_raw_reads"] = np.log1p(pd.to_numeric(df["raw_reads"], errors="coerce"))
```

```
for c in ["gestational_age", "bmi", "age", "map_ratio", "dup_ratio",
         "y_fraction", "unique_rate", "log_raw_reads"]:
```

```
    if c in df.columns:
```

```
        df[c] = pd.to_numeric(df[c], errors="coerce")
```

目标变量取对数

```
df["y_log"] = np.log(df["y_fraction"] + 1e-6)
```

#4.3 组装建模数据（连续自变量）

```
features = [
    "gestational_age", "bmi", "log_raw_reads", "unique_rate",
    "age", "map_ratio", "dup_ratio",
]
cols_need = ["mother_id", "y_log"] + features
dfm = df[cols_need].dropna().copy()

# 标准化
for c in features:
    mu, sd = dfm[c].mean(), dfm[c].std(ddof=0)
    dfm[c + "_z"] = (dfm[c] - mu) / sd if (np.isfinite(sd) and sd > 0) else dfm[c]
features_z = [c + "_z" for c in features]
```

4.4 MixedLM（随机截距：孕妇）

```
formula = "y_log ~ " + " + ".join(features_z)
print("公式：", formula)

model = smf.mixedlm(formula=formula, data=dfm, groups=dfm["mother_id"])
res = model.fit(method="lbfgs", reml=False, maxiter=200)

print("\n=== MixedLM 结果（log(y) 主模型，BMI 连续） ===")
print(res.summary())
print("AIC=% .3f BIC=% .3f LogLik=% .3f" % (res.aic, res.bic, res.llf))
```

4.5 R^2 计算（Nakagawa & Schielzeth + pseudo- R^2 ）

固定效应线性预测

```
X = res.model.exog          # 设计矩阵（固定效应）
beta = res.fe_params.values # 固定效应系数
y_hat_fixed = X @ beta      # 仅固定效应部分
var_fix = np.var(y_hat_fixed, ddof=1) # 固定效应解释的方差
```

随机效应方差（这里只用了随机截距）

res.cov_re 可能是 DataFrame 或 ndarray

```
cov_re = res.cov_re
if hasattr(cov_re, "iloc"):
    var_re = float(cov_re.iloc[0, 0])
else:
    var_re = float(np.asarray(cov_re)[0, 0])
```

残差方差

```
var_resid = float(res.scale)
```

Marginal / Conditional R^2

```
den = var_fix + var_re + var_resid
R2_marginal = var_fix / den if den > 0 else np.nan
R2_conditional = (var_fix + var_re) / den if den > 0 else np.nan
```

```

# Pseudo-R2: 相关系数平方 (基于  $\log(y)$ )
y = dfm["y_log"].values
yhat = res.fittedvalues.values
R2_pseudo = np.corrcoef(y, yhat)[0, 1] ** 2

print("\n=== R2 指标 ===")
print(f"Marginal R2 (仅固定效应)      : {R2_marginal:.4f}")
print(f"Conditional R2 (含随机效应) : {R2_conditional:.4f}")
print(f"Pseudo-R2 (corr2, 直观)      : {R2_pseudo:.4f}")

# 4.6 残差诊断 (log 模型)
dfm["fitted"] = res.fittedvalues
dfm["resid"] = dfm["y_log"] - dfm["fitted"]

plt.figure(figsize=(8, 5))
sns.residplot(x=dfm["fitted"], y=dfm["resid"], lowess=True, line_kws={"color": "red"})
plt.axhline(0, ls="--", c="gray")
plt.title("残差与拟合值关系图")
plt.xlabel("拟合值 (log 模型)"); plt.ylabel("残差")
plt.tight_layout();
plt.savefig("问1.4:残差与拟合值关系图.png", dpi=300, bbox_inches="tight")
plt.show()

```

问题2:

```

# ----- 9.1 K-means 分组 -----
# 与“原题分组”保持相同组数; 若没有 BMI组 列, 则默认 5 组
K = int(d['BMI组'].nunique()) if 'BMI组' in d.columns else 5
km_model = KMeans(n_clusters=K, random_state=42, n_init=20).fit(d[[col_bmi]].values)
centers = np.sort(km_model.cluster_centers_.ravel())
# 中心间中点作为切点
cuts_km = [-np.inf] + [float((centers[i]+centers[i+1])/2) for i in range(K-1)] +
[ np.inf]
labels_km = [f'K{K}_{i+1}' for i in range(K)]
d['BMI组_KM'] = pd.cut(d[col_bmi], bins=cuts_km, labels=labels_km, right=False)

model_km, cind_km, tab_km = compare_grouping(
    d, 'BMI组_KM', title='K-means 分组', show_plot=False
)

# ----- 9.2 DP 风险最优分箱 -----
# 选一个临床“决策时点” t*: 优先用你之前原题分组 res 的“推荐日”中位数作为参考
t_star = 170
try:
    mday = np.nanmedian(pd.to_numeric(res['推荐日'], errors='coerce'))
    if np.isfinite(mday):
        t_star = int(mday)
except Exception:
    pass

```

```

print("DP 分箱使用决策时点 t* =", t_star)

# 在 t* 之前达标(且事件=1) 记为 1; 否则 0
y_bin = ((d['检测孕周_days'].values <= t_star) & (d['event'].values==1)).astype(int)
x_val = d[col_bmi].values

def dp_optimal_binning(x, y, K=5, min_bin=40):
    """
    在有序 x 上做动态规划, 找到 K 个箱 (K-1 个切点),
    目标: 最小化各箱二分类负对数似然之和; 每箱样本 >= min_bin。
    """
    order = np.argsort(x)
    x_sorted = x[order]; y_sorted = y[order]
    uniq, idx = np.unique(x_sorted, return_index=True)
    idx = np.r_[idx, len(x_sorted)]
    n = len(uniq)
    cnt = np.diff(idx)
    pos = np.array([y_sorted[idx[i]:idx[i+1]].sum() for i in range(n)], dtype=float)
    C = np.r_[0, np.cumsum(cnt)]
    P = np.r_[0, np.cumsum(pos)]

    def seg_cost(i, j):
        n_seg = C[j]-C[i]; p_seg = P[j]-P[i]
        if n_seg < max(min_bin, 1): return np.inf
        p_hat = np.clip(p_seg / n_seg, 1e-6, 1-1e-6)
        return - (p_seg*np.log(p_hat) + (n_seg-p_seg)*np.log(1-p_hat))

    dp = np.full((K+1, n+1), np.inf); pre = np.full((K+1, n+1), -1, dtype=int)
    dp[0,0] = 0.0
    for k in range(1, K+1):
        for j in range(1, n+1):
            for i in range(0, j):
                if (C[j]-C[i]) < min_bin: continue
                val = dp[k-1,i] + seg_cost(i, j)
                if val < dp[k, j]:
                    dp[k, j] = val; pre[k, j] = i

    if not np.isfinite(dp[K,n]):
        raise RuntimeError("DP 未找到满足最小箱样本数的切分, 请调大 min_bin 或减小
K。")

    cuts_idx = []
    k, j = K, n
    while k>0:
        i = pre[k, j]; cuts_idx.append((i, j)); k, j = k-1, i
    cuts_idx = cuts_idx[::-1]

    # 唯一值坐标 -> 实际切点
    edges = [-np.inf]

```

```

for (i, j), (i2, j2) in zip(cuts_idx[:-1], cuts_idx[1:]):
    left_max = uniq[j-1]; right_min = uniq[j]
    edges.append(float((left_max + right_min)/2))
edges.append(np.inf)
return edges, cuts_idx

```

```

K_target = K # 与原题分组个数保持一致
edges_dp, idx_dp = dp_optimal_binning(x_val, y_bin, K=K_target, min_bin=max(30,
int(len(d)*0.01)))
d['BMI组_DP'] = pd.cut(d[col_bmi], bins=edges_dp, right=False)

```

```

model_dp, cind_dp, tab_dp = compare_grouping(
    d, 'BMI组_DP', title='DP 风险最优分箱', show_plot=False
)

```

问题3:

问题4:

```

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

```

```

from xgboost.sklearn import XGBClassifier

```

```

from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler

```

```

from sklearn.model_selection import StratifiedKFold, RepeatedStratifiedKFold
from sklearn.metrics import (
    f1_score, recall_score, precision_recall_curve,
    roc_auc_score, average_precision_score, accuracy_score,
    roc_curve, confusion_matrix
)

```

```

from imblearn.over_sampling import SMOTE, RandomOverSampler
from imblearn.under_sampling import RandomUnderSampler
from imblearn.combine import SMOTEENN, SMOTETomek
from imblearn.pipeline import Pipeline as ImbPipeline

```

3 model

```

def run_xgboost(SAMPLER, USE_REPEATED_CV, N_SPLITS, N_REPEATS, THRESH_MODE, MIN_RECALL):
    # 读取数据
    df = pd.read_excel("附件(问题四).xlsx")
    y = df["染色体的非整倍体"].astype(int).values

```

基础特征(从2. 特征选择得到)

```

base_feats = [
    "X染色体浓度", "检测孕周", "被过滤掉读段数的比例", "13号染色体的GC含量",

```



```

    "生产次数", "重复读段的比例", "年龄", "孕妇BMI",
    "21号染色体的Z值", "X染色体的Z值", "GC含量",
    "13号染色体的Z值", "18号染色体的Z值", "唯一比对的读段数", "原始读段数",
    "18号染色体的GC含量", "21号染色体的GC含量"
]
X_df = df[base_feats].copy()

#基础数值化
X_df = X_df.apply(pd.to_numeric, errors="coerce")

#交互 + 二次 + BMI×孕周
if set(["X染色体浓度", "检测孕周"]).issubset(X_df.columns):
    X_df["X浓度x孕周"] = X_df["X染色体浓度"] * X_df["检测孕周"]
if set(["X染色体浓度", "GC含量"]).issubset(X_df.columns):
    X_df["X浓度xGC"] = X_df["X染色体浓度"] * X_df["GC含量"]
if "X染色体浓度" in X_df.columns:
    X_df["(X浓度)^2"] = X_df["X染色体浓度"] ** 2
if "检测孕周" in X_df.columns:
    X_df["(孕周)^2"] = X_df["检测孕周"] ** 2
if "孕妇BMI" in X_df.columns and "检测孕周" in X_df.columns:
    bmi_dum = pd.get_dummies(X_df["孕妇BMI"].astype(int), prefix="BMI",
drop_first=True)
    for c in bmi_dum.columns: # e.g. BMI_2, BMI_3
        X_df[f"{c}x孕周"] = bmi_dum[c] * X_df["检测孕周"]

#分段/统计组合特征
# 1) 分段(分箱)特征
if "检测孕周" in X_df.columns:
    X_df["孕周_bin"] = pd.cut(
        X_df["检测孕周"], bins=[-np.inf, 12, 20, np.inf],
        labels=["W_1t12", "W_12_20", "W_gt20"]
    )
if "年龄" in X_df.columns:
    X_df["年龄_bin"] = pd.cut(
        X_df["年龄"], bins=[-np.inf, 30, 40, np.inf],
        labels=["Age_30", "Age_30_40", "Age_40"]
    )

# one-hot
for col in ["孕周_bin", "年龄_bin", "抽血_bin"]:
    if col in X_df.columns:
        d = pd.get_dummies(X_df[col], prefix=col, drop_first=True)
        X_df = pd.concat([X_df.drop(columns=[col]), d], axis=1)

# 2) 统计组合特征
eps = 1e-9
if set(["21号染色体的Z值", "13号染色体的Z值"]).issubset(X_df.columns):
    X_df["Z21_13_ratio"] = X_df["21号染色体的Z值"] / (X_df["13号染色体的Z值"]
    ].abs() + eps)

```

```

X_df["Z21_13_diff"] = X_df["21号染色体的Z值"] - X_df["13号染色体的Z值"]
if set(["18号染色体的Z值", "13号染色体的Z值"]).issubset(X_df.columns):
    X_df["Z18_13_ratio"] = X_df["18号染色体的Z值"] / (X_df["13号染色体的Z值"]
    ].abs() + eps)
    X_df["Z18_13_diff"] = X_df["18号染色体的Z值"] - X_df["13号染色体的Z值"]
    if set(["21号染色体的Z值", "18号染色体的Z值"]).issubset(X_df.columns):
        X_df["Z21_18_ratio"] = X_df["21号染色体的Z值"] / (X_df["18号染色体的Z值"]
        ].abs() + eps)
        X_df["Z21_18_diff"] = X_df["21号染色体的Z值"] - X_df["18号染色体的Z值"]

    if set(["13号染色体的GC含量", "18号染色体的GC含量"]).issubset(X_df.columns):
        X_df["GC_13_18_diff"] = X_df["13号染色体的GC含量"] - X_df["18号染色体的GC
含量"]
    if set(["21号染色体的GC含量", "18号染色体的GC含量"]).issubset(X_df.columns):
        X_df["GC_21_18_diff"] = X_df["21号染色体的GC含量"] - X_df["18号染色体的GC
含量"]

    if set(["唯一比对的读段数", "原始读段数"]).issubset(X_df.columns):
        X_df["unique_read_ratio"] = X_df["唯一比对的读段数"] / (X_df["原始读段数"]
+ eps)

key_cont = ["X染色体浓度", "检测孕周", "GC含量"]
for grp_prefix in ["年龄_bin", "抽血_bin", "孕周_bin"]:
    ohe_cols = [c for c in X_df.columns if c.startswith(grp_prefix + "_")]
    for g in ohe_cols:
        for v in key_cont:
            if v in X_df.columns:
                X_df[f"{g}x{v}"] = X_df[g].astype(float) *
X_df[v].astype(float)

#连续/二元列划分
is_binary = X_df.apply(lambda s: pd.api.types.is_numeric_dtype(s) and s.nunique()
<= 2)
cat_cols = is_binary[is_binary].index.tolist()
con_cols = [c for c in X_df.columns if c not in cat_cols]
feature_names = con_cols + cat_cols

#预处理
preprocess = ColumnTransformer(
    transformers=[
        ("num", Pipeline([
            ("imp", SimpleImputer(strategy="median")),
            ("sc", StandardScaler())
        ]), con_cols),
        ("bin", Pipeline([
            ("imp", SimpleImputer(strategy="most_frequent")),
        ]), cat_cols)
    ],
    remainder="drop"

```

```

)

# 模型与采样器
xgb_c = XGBClassifier(
    booster="gblinear",
    learning_rate=0.01,
    n_estimators=10,
    objective="binary:logistic",
    random_state=42
)

if SAMPLER.upper() == "SMOTE":
    sampler = SMOTE(k_neighbors=5, random_state=42)
elif SAMPLER.upper() == "SMOTEENN":
    sampler = SMOTEENN(random_state=42)
elif SAMPLER.upper() == "SMOTETOMEK":
    sampler = SMOTETomek(random_state=42)
elif SAMPLER.upper() == "UP":
    sampler = RandomOverSampler(sampling_strategy=0.5)
elif SAMPLER.upper() == "DOWN":
    sampler = RandomUnderSampler(sampling_strategy=1)
else:
    raise ValueError("SAMPLER 必须是 'SMOTE'、'SMOTEENN'、'SMOTETOMEK'、'UP'
或 'DOWN'")

pipe = ImbPipeline(steps=[
    ("pre", preprocess),
    ("resample", sampler),
    ("clf", xgb_c)
])

# 阈值函数
def choose_threshold(y_true, prob, mode="max_f1", min_recall=0.6):
    p, r, thr = precision_recall_curve(y_true, prob)
    thr = np.append(thr, 1.0)
    if mode == "max_f1":
        f1 = 2 * p * r / (p + r + 1e-12)
        idx = np.nanargmax(f1)
    elif mode == "min_recall":
        mask = r >= min_recall
        f1 = 2 * p * r / (p + r + 1e-12)
        idx = np.nanargmax(np.where(mask, f1, -1)) if np.any(mask) else
np.argmax(r)
    else:
        raise ValueError("mode 只能是 'max_f1' 或 'min_recall'")
    return float(thr[idx]), p, r, thr

# 交叉验证
cv = (RepeatedStratifiedKFold(n_splits=N_SPLITS, n_repeats=N_REPEATS,

```

```

random_state=42)
        if USE_REPEATED_CV else
        StratifiedKFold(n_splits=N_SPLITS, shuffle=True, random_state=42))

    roc_list, pr_list, f1_list, recall_list, acc_list, coef_list, thresh_list = [],
    [], [], [], [], []
    X_all = X_df.copy()

    for fold, (tr, va) in enumerate(cv.split(X_all, y), 1):
        X_tr, X_va = X_all.iloc[tr], X_all.iloc[va]
        y_tr, y_va = y[tr], y[va]

        pipe.fit(X_tr, y_tr)
        prob_va = pipe.predict_proba(X_va)[: , 1]

        best_thr, prec, rec, thr_curve = choose_threshold(
            y_va, prob_va, mode=THRESH_MODE, min_recall=MIN_RECALL
        )
        thresh_list.append(best_thr)
        pred_va = (prob_va >= best_thr).astype(int)

        roc = roc_auc_score(y_va, prob_va)
        pr_auc = average_precision_score(y_va, prob_va)
        f1 = f1_score(y_va, pred_va)
        rec_score = recall_score(y_va, pred_va)
        acc = accuracy_score(y_va, pred_va)

        roc_list.append(roc)
        pr_list.append(pr_auc)
        f1_list.append(f1)
        recall_list.append(rec_score)
        acc_list.append(acc)

        print(f"[Fold {fold}] thr={best_thr:.3f} | ROC-AUC={roc:.3f} | PR-
AUC={pr_auc:.3f} | "
              f"F1={f1:.3f} | Recall={rec_score:.3f} | ACC={acc:.3f}")

        # 如果 gblinear 未暴露 coef_, 则跳过
        try:
            clf = pipe.named_steps["clf"]
            coef = clf.coef_.ravel()
            coef_list.append(pd.Series(coef, index=feature_names))
        except Exception:
            pass

    # 总结模型表现
    def _stat(x): return np.mean(x), np.std(x)
    roc_m, roc_s = _stat(roc_list)
    pr_m, pr_s = _stat(pr_list)

```

```

fl_m, fl_s = _stat(fl_list)
recall_m, recall_s = _stat(recall_list)
acc_m, acc_s = _stat(acc_list)
thr_m, thr_s = _stat(thresh_list)

print("\n=== CV 成绩 (均值 ± 标准差) ===")
print(f"Sampler : {SAMPLER} | CV : {'Repeated' if USE_REPEATED_CV else 'KFold'}")
print(f"ROC-AUC : {roc_m:.3f} ± {roc_s:.3f}")
print(f"PR-AUC : {pr_m:.3f} ± {pr_s:.3f}")
print(f"F1 : {f1_m:.3f} ± {f1_s:.3f}")
print(f"Recall : {recall_m:.3f} ± {recall_s:.3f}")
print(f"ACC : {acc_m:.3f} ± {acc_s:.3f}")
print(f"Best thr (mean±std): {thr_m:.3f} ± {thr_s:.3f}")

# A) 收集 OOF 概率 (与上文相同的 cv / pipe)
oof_prob = np.zeros_like(y, dtype=float)
oof_mask = np.zeros_like(y, dtype=bool)
for fold, (tr, va) in enumerate(cv.split(X_all, y), 1):
    X_tr, X_va = X_all.iloc[tr], X_all.iloc[va]
    y_tr = y[tr]
    pipe.fit(X_tr, y_tr)
    oof_prob[va] = pipe.predict_proba(X_va)[: , 1]
    oof_mask[va] = True
assert oof_mask.all(), "有样本没被覆盖"

# B) 基于 OOF 概率求阈值 (Youden + 目标 Sens/Spec)
fpr, tpr, thr_roc = roc_curve(y, oof_prob)
youden = tpr - fpr
tau_youden = float(thr_roc[np.argmax(youden)])

thr_grid = np.linspace(0.01, 0.99, 99)
sens_list, spec_list = [], []
for thr in thr_grid:
    pred = (oof_prob >= thr).astype(int)
    tn, fp, fn, tp = confusion_matrix(y, pred, labels=[0, 1]).ravel()
    sens = tp / (tp + fn + 1e-9)
    spec = tn / (tn + fp + 1e-9)
    sens_list.append(sens)
    spec_list.append(spec)

SENS_TARGET = 0.75
SPEC_TARGET = 0.85
cand_low = [t for t, s in zip(thr_grid, sens_list) if s >= SENS_TARGET]
cand_high = [t for t, s in zip(thr_grid, spec_list) if s >= SPEC_TARGET]
tau_low = float(max(cand_low)) if cand_low else tau_youden # 正常阈 (偏高召
回)
tau_high = float(min(cand_high)) if cand_high else tau_youden # 异常阈 (偏高特
异)

```

```

print("\n=== 女胎异常判定方法（基于 OOF 概率）===")
print(f"• 异常: prob ≥  $\tau_{high}$  = {tau_high:.3f}")
print(f"• 正常: prob ≤  $\tau_{low}$  = {tau_low:.3f}")
print(f"• 介于其间: 建议复诊")
print(f"（参考: Youden 最优阈值  $\tau_{youden}$  = {tau_youden:.3f}）")

# C) 三分判定标签
tri_label = np.where(oof_prob >= tau_high, 1, np.where(oof_prob <= tau_low, 0, -
1))

print(f"\n三分判定: 明确异常={np.sum(tri_label==1)}, 明确正常
={np.sum(tri_label==0)}, 建议复诊={np.sum(tri_label==-1)}")

# D) 生成临床指标范围表 (Q25 - Q75, 含中位数)
features_for_report = [
    "检测孕周", "重复读段的比例", "21号染色体的Z值", "X染色体的Z值",
    "被过滤掉读段数的比例", "13号染色体的GC含量", "GC含量", "X染色体浓度",
    "年龄", "孕妇BMI", "生产次数"
]
features_for_report = [c for c in features_for_report if c in df.columns]

def _fmt_num(x):
    try:
        v = float(x)
        s = f"{v:.2f}"
        return "0.00" if s == "-0.00" else s
    except Exception:
        return str(x)

def _describe_range(series):
    vals = pd.to_numeric(series, errors="coerce").dropna().values
    if len(vals) == 0:
        return "无样本"
    q25, med, q75 = np.percentile(vals, [25, 50, 75])
    return f"{_fmt_num(q25)} - {_fmt_num(q75)} (中位数 {_fmt_num(med)})"

def _describe_cat(series):
    vc = series.value_counts(dropna=True)
    tot = vc.sum()
    return ", ".join([f"{idx}:{cnt} ({cnt/tot:.0%})" for idx, cnt in
vc.items()]) if tot > 0 else "无样本"

rows = []
for col in features_for_report:
    row = {"指标": col}
    for g, name in zip([1, 0, -1], ["明确异常", "明确正常", "建议复诊"]):
        s = df.loc[tri_label == g, col]
        if pd.api.types.is_numeric_dtype(df[col]) or
np.issubdtype(df[col].dtype, np.number):
            row[name] = _describe_range(s)

```

```

        else:
            row[name] = _describe_cat(s)
        rows.append(row)

summary_df = pd.DataFrame(rows, columns=["指标", "明确异常", "明确正常", "建议复诊"])

print("\n=== 各指标在三分判定下的区间 (Q25 - Q75, 含中位数) ===")
print(summary_df)
return {
    "tau_low": tau_low,
    "tau_high": tau_high,
    "tau_youden": tau_youden,
    "oof_prob": oof_prob,
    "tri_label": tri_label,
    "summary_df": summary_df
}

SAMPLER = "UP"                # 备选: "SMOTE", "SMOTEENN", "SMOTETomek"
USE_REPEATED_CV = True        # True 用 RepeatedStratifiedKFold
N_SPLITS = 5                  # 折数
N_REPEATS = 3                 # 重复次数 (仅在 USE_REPEATED_CV=True 时生效)
THRESH_MODE = "max_f1"        # "max_f1" 或 "min_recall"
MIN_RECALL = 0.80             # 若 THRESH_MODE="min_recall", 满足该召回的最大F1阈值
run_xgboost(SAMPLER, USE_REPEATED_CV, N_SPLITS, N_REPEATS, THRESH_MODE, MIN_RECALL)

```